

Lab02: sistema de trading con indicadores técnicos, walk-forward y detección de régimen

Reporte ejecutivo, nivel B (equipos de 2 integrantes)

Curso: Microestructuras y Sistemas de Trading, ITESO Guadalajara

Equipo 7: Gian Carlo Campos Sayavedra (GCCS11) y Juan Pablo Barba González (JPBAG0)

Repositorio: github.com/GCCS11/Lab02_MyST_Equipo7

Parámetros congelados antes de evaluar en prueba: commit 43aa031 (docs/theta_frozen.json)

Fecha: octubre de 2026

Activo y datos: BTCUSDT, barras de 5 minutos (btc_project_train.csv y btc_project_test.csv, Canvas). Entrenamiento de 2022-06-01 a 2023-12-31 y prueba de 2023-12-31 a 2024-06-03.

1. Resumen ejecutivo

Se construyó una estrategia sistemática sobre BTCUSDT que combina tres indicadores técnicos de tres familias con una regla de confirmación de 2 de 3, un motor de backtesting orientado a eventos con comisión de 0.125% por lado, optimización con Optuna (TPE) y evaluación por walk-forward semanal. Como nivel B, se agregó detección de régimen de mercado (reversión o rango, tendencia y crisis) y se comparó un único conjunto de parámetros contra uno por régimen. **La conclusión central es que no hay evidencia de una ventaja explotable:** el método funciona y es reproducible, pero la ventaja que el optimizador encuentra dentro de muestra no sobrevive fuera de ella.

- **Degradación:** el Calmar mediano de entrenamiento de las 65 ventanas es 53.6 y fuera de muestra, encadenado, 0.25. Ese contraste exagera la caída (el 53.6 es el mejor de 150 intentos y anualiza un solo mes), así que la evidencia principal es otra: fuera de muestra, el retorno bruto por operación (0.23% a 0.25%) queda en el costo de ida y vuelta (0.25%).
- **Walk-forward (65 semanas fuera de muestra):** un solo θ con filtro de calidad, +5.1% (Sharpe 0.31); un θ por régimen, -35.1% (Sharpe -1.55); comprar y mantener, +90.1% (Sharpe 1.51).
- **Prueba (33 días con datos, parámetros congelados):** +0.7% con 8 operaciones y +1.0% con 9 operaciones, contra +16.4% de comprar y mantener. Con tan pocas operaciones el resultado no se distingue de cero.
- **Régimen:** el retorno por operación no difiere entre reversión y tendencia (diferencia de 0.02 puntos porcentuales, $p = 0.93$). La crisis tuvo 3 operaciones en entrenamiento y no aparece en la prueba.
- **Robustez:** el Calmar nunca se vuelve negativo con variaciones de $\pm 20\%$, pero 6 de 18 variaciones pierden la mitad o más; m , r , $\max_hold$ y n_atr forman un pico, no una meseta. La comisión de equilibrio es 47.3 puntos base por lado (3.8 veces la del lab), pero solo dentro de muestra.
- **Esfuerzo de optimización:** 31,800 configuraciones evaluadas; la corrida completa tarda entre 9 y 21 minutos según la carga de la máquina (551 s en la corrida final registrada en docs/run_log.txt y 1,234 s en una ejecución anterior, visible en el historial de git). El θ recalculado coincidió con el congelado en cada corrida completa.

2. Datos, calidad y tratamiento de huecos

Los dos archivos contienen barras vacías, barras fuera de la rejilla de 5 minutos y huecos de datos. La tabla resume la auditoría (docs/tables/auditoria_datos.csv).

Concepto	Entrenamiento	Prueba
Filas crudas	166,450	9,387
Barras con OHLC vacío	3,745 (2.25%), 85% entre 22:00 y 23:59 UTC	17
Barras fuera de la rejilla de 5 min (planas, sin volumen)	573	3
Barras limpias	162,132	9,366 (sin la barra compartida con entrenamiento)
Cortes mayores a 6 horas	3 (22 h 34 min, 2 días, 11 h 36 min)	1 (122 días, de 2023-12-31 a 2024-05-02)
Tramos continuos (barras)	4 (80,698; 3,227; 7,604 y 70,603)	2 (287 y 9,079)

Tratamiento. No se rellenó ningún precio: rellenar crea barras que nunca existieron, reduce artificialmente la volatilidad y permite operar a precios inexistentes. Se descartan las barras vacías y las fuera de rejilla; un hueco mayor a 6 horas abre un tramo nuevo (cualquier umbral entre 3 y 11 horas produce la misma segmentación); los indicadores y las variables de régimen se calculan dentro de cada tramo y valen cero o quedan sin etiqueta mientras se calientan; ninguna posición cruza un corte, porque se cierra al cierre de la última barra del tramo; las ventanas del walk-forward no cruzan cortes, por lo que los tramos de 3,227 y 7,604 barras, más cortos que una ventana de 37 días, no producen ventanas; y el benchmark encadena sus retornos dentro de cada tramo para que el salto de un hueco no cuente como

ganancia ni pérdida.

Consecuencias medidas. El tramo de prueba de mayo y junio dura 31 días, no tiene historia previa y sus primeros 2,016 bars no tienen régimen etiquetado (la ventana de las variables es de una semana). Por eso el θ por régimen no pudo operar en mayo hasta alrededor del 9 (el θ único, que no usa etiquetas, operó desde el 3), y el 31 de diciembre, que continúa el último tramo de entrenamiento, aportó 1 y 2 de las 8 y 9 operaciones. Los datos tienen además una particularidad: el retorno de 5 minutos tiene autocorrelación de 0.09 en el rezago 1 que se desvanece desde el rezago 2, y el salto entre el cierre y la apertura siguiente tiene una desviación de 6.6 puntos base, un efecto de cómo se construyen las barras.

3. Estrategia

3.1 Indicadores y regla de confirmación

Se evaluaron cinco candidatos y se eligió un indicador por familia con la menor correlación media entre sus señales (0.36, docs/tables/correlacion_trios.csv), sin mirar retornos. No se usa volumen porque los datos lo traen vacío o poco confiable.

Indicador	Familia	Señal $x_{i,t}$ en $\{-1, 0, +1\}$	Parámetros
Donchian	Tendencia	+1 si el cierre rompe el máximo de las n barras previas, -1 si rompe el mínimo; conserva la dirección de la última ruptura	n_{donchian}
ROC	Momento	Signo del retorno de las últimas n barras	n_{roc}
Keltner	Volatilidad	+1 si el cierre supera $\text{EMA} + k \cdot \text{ATR}$, -1 si queda bajo $\text{EMA} - k \cdot \text{ATR}$, 0 dentro	$n_{\text{ema}}, n_{\text{atr}}, k$

Regla de confirmación. Sea $L_t = \sum_j 1[x_{j,t} = +1]$ el número de indicadores con señal larga y $S_t = \sum_j 1[x_{j,t} = -1]$ el de señal corta, con $j \in \{\text{Donchian}, \text{ROC}, \text{Keltner}\}$. La señal combinada es: $s_t = +1$ si $L_t \geq 2$; $s_t = -1$ si $S_t \geq 2$; $s_t = 0$ en otro caso.

3.2 Entradas, salidas, tamaño y costos

- **Ejecución:** la señal al cierre de t se ejecuta en la apertura de $t+1$. Solo se abre una posición si la distancia al target es al menos 0.5% del precio (el doble del costo de ida y vuelta).
- **Salidas:** stop-loss en $P_{\text{in}} - \text{lado} \cdot m \cdot \text{ATR}$ y take-profit en $P_{\text{in}} + \text{lado} \cdot r \cdot m \cdot \text{ATR}$; si ambos caen en la misma barra gana el stop (convención conservadora); si la barra abre más allá de un nivel, se llena a la apertura (gap). También salen la señal opuesta (tras *signal_exit_after* barras), el holding máximo y el cierre forzado al final de cada tramo.
- **Tamaño:** $q = \min(\rho \cdot V / (m \cdot \text{ATR}), V / (P \cdot (1 + c)))$, con presupuesto de riesgo ρ y capital V ; el segundo término impide el apalancamiento, que el lab no permite. Capital inicial de 1,000,000 USD, largos y cortos.
- **Costos:** comisión de 0.125% en cada apertura y cada cierre (c). Slippage y costo de préstamo en cero en el caso base; se exploran como sensibilidad en la sección 8.
- **Supuestos declarados:** el cierre forzado al final de un tramo usa el saber de que sigue un hueco de datos (en operación real la posición habría quedado abierta; es una simplificación conservadora que en la prueba costó 1,550 y 515 USD); Sharpe y Sortino con tasa libre de riesgo cero y anualización de 365×288 barras; una sola posición a la vez.

4. Optimización y walk-forward

Se optimizan diez hiperparámetros con Optuna (muestreador TPE, semilla 42), 150 pruebas por ventana, maximizando el Calmar. Una configuración con menos operaciones que el mínimo (10 por ventana de entrenamiento, 30 al ajustar sobre todo el entrenamiento; proporcional al peso del régimen en el caso por régimen, con piso de 3) recibe una penalización en lugar de su Calmar, para evitar configuraciones con pocas operaciones ganadoras.

Parámetro	Rango	Parámetro	Rango
n_donchian, n_roc, n_ema, n_atr	12 a 864 barras (escala log)	r (target / stop)	1.5 a 4
k (ancho Keltner)	1 a 3	max_hold	1 a 10 días
m (stop en múltiplos de ATR)	10 a 60	signal_exit_after	0, 1 día o nunca
		p (riesgo por operación)	0.25% a 3% (escala log)

Walk-forward. Ventana de entrenamiento de 1 mes (8,640 barras), prueba de 1 semana (2,016 barras) y paso semanal, siempre dentro de un tramo continuo: salen 65 ventanas (35 del primer tramo largo y 30 del último). Cada semana de prueba arranca sin posición y cierra a la fuerza al terminar, lo que castiga el holding largo (56 de 430 salidas del caso por régimen). Los indicadores usan datos previos a la prueba para calentarse, pero no se abre ninguna posición antes de ella.

Protocolo de evaluación final. Los parámetros se optimizaron una sola vez sobre todo el entrenamiento (150 pruebas, un θ único y un θ por régimen), se guardaron en docs/theta_frozen.json y se commitearon (43aa031) **antes** de abrir el archivo de prueba, que se evaluó una sola vez. El θ recalculado por main.py coincidió con el congelado en cada corrida completa (la última, en docs/run_log.txt).

Concepto	Configuraciones evaluadas
Walk-forward, un solo θ (65 ventanas $\times$ 150)	9,750
Walk-forward, un θ por régimen (143 optimizaciones de régimen $\times$ 150)	21,450
θ congelado sobre todo el entrenamiento (4 optimizaciones $\times$ 150)	600
Total	31,800
Tiempo total de la corrida completa (sin paralelizar, MacBook Pro)	551 s en la corrida final (unos 9 minutos); 1,234 s en una anterior

Decisiones tomadas después de ver resultados (declaradas para no inflar la evidencia): se ampliaron los rangos de m y max_hold y se agregó el parámetro signal_exit_after tras siete corridas exploratorias en entrenamiento, y se agregó el filtro de calidad (operar la semana solo si el mejor Calmar de entrenamiento es positivo) tras ver que 14 ventanas sin ventaja dentro de muestra (13 de ellas con salida inmediata por señal) producían la mayor parte de la pérdida. El efecto de ese filtro medido en entrenamiento es optimista; la prueba es la evaluación que cuenta. La bitácora completa está en docs/EXPERIMENTS.md.

5. Resultados

Entrenamiento corresponde a las 65 semanas fuera de muestra del walk-forward encadenadas; prueba, a los parámetros congelados. Sharpe, Sortino y Calmar se anualizan contando barras (no días de calendario), por lo que en la prueba, de 33 días, son poco informativas.

Entrenamiento (walk-forward, 65 semanas)

Estrategia	Retorno	Sharpe	Sortino	Calmar	Máx. drawdown	Win rate	Operaciones
θ único (con filtro de calidad)	+5.1%	0.31	0.45	0.25	-16.1%	39.8%	354
θ por régimen	-35.1%	-1.55	-2.18	-0.75	-39.4%	37.2%	430
Comprar y mantener	+90.1%	1.51	2.14	1.78	-37.9%	n/a	0

Prueba (parámetros congelados, 33 días)

Estrategia	Retorno	Sharpe	Sortino	Calmar	Máx. drawdown	Win rate	Operaciones
θ único	+0.7%	0.71	1.02	2.92	-2.6%	37.5%	8
θ por régimen	+1.0%	4.96	7.51	31.47	-0.4%	55.6%	9
Comprar y mantener	+16.4%	4.43	6.45	57.19	-7.9%	n/a	0

Cómo leerlo. En la prueba, el Sharpe y el Calmar del θ por régimen parecen altos pero no significan nada: son 9 operaciones y 1% de retorno, anualizados sobre un mes casi sin caída. El win rate de 5 de 9 tiene un intervalo de confianza del 95% de 27% a 81%. Su Sharpe supera al de comprar y mantener porque la estrategia arriesgó muy poco capital: estuvo invertida alrededor del 78% de las barras, pero con una exposición media cercana al 6% del capital (volatilidad de 2.3% anual contra 40.4% de BTC), mientras BTC subía 16%. En retorno, comprar y mantener le gana 16 a 1 (docs/tables/exposicion_test.csv).




Figura 1. Valor del portafolio en entrenamiento (semanas fuera de muestra del walk-forward) y en prueba, con su benchmark. Las bandas grises son huecos de datos: las curvas encadenan sin saltos. El θ único queda plano entre agosto y octubre de 2023 porque el filtro de calidad lo dejó en efectivo.




Figura 2. Curva de drawdown correspondiente a la figura 1.




Figura 3a. Retornos mensuales, trimestrales y anuales del θ por régimen en entrenamiento (en prueba, figura 3b).




Figura 3b. Retornos mensuales, trimestrales y anuales del θ por régimen en prueba. Las tablas de los demás casos están en docs/tables.

6. Análisis de régimen (nivel B)

6.1 Metodología y variables

Las variables se calculan sobre una ventana móvil de una semana (2,016 barras), dentro de cada tramo, y la etiqueta se actualiza cada hora. Son causales: la etiqueta en t solo usa datos hasta t , y una prueba lo verifica.

- **Volatilidad:** desviación estándar de los retornos logarítmicos. Separa la crisis (mediana 0.0022 contra 0.0011).
- **Fuerza de tendencia:** R^2 de la regresión lineal del log-precio contra el tiempo. Separa la tendencia (mediana 0.70) del rango (0.15).
- **Autocorrelación horaria** (candidata a medir reversión): se descartó de la clasificación. Con ella (exploración previa), el silhouette de K-means cae de 0.47 a 0.29, las rachas se acortan y el cluster de crisis pasa de 9% a 25% del tiempo; su variación en el tiempo es del mismo tamaño que la que produciría el azar (0.074 contra 0.061 a 0.075 en una simulación sin estructura), y no separa los regímenes (-0.004 en reversión, -0.007 en tendencia).

Reglas. Crisis si la volatilidad supera el cuantil 90 de la de entrenamiento (0.00168); tendencia si no es crisis y $R^2 \geq 0.5$; reversión en los demás casos. Por eso el régimen que llamamos reversión es en realidad **mercado de rango** (precio sin dirección y volatilidad normal): no se midió reversión a la media. En el walk-forward los umbrales se reajustan con datos hasta el final de cada ventana de entrenamiento. En una exploración previa, cuyo código se conserva en la etiqueta de git *exploracion-regimenes* (docs/EXPERIMENTS.md), se compararon también K-means (silhouette 0.47, partición casi idéntica) y un HMM con probabilidades filtradas, no la ruta de Viterbi (silhouette 0.25, con un estado de crisis que ocupa 35% del tiempo); se eligieron las reglas por cumplir las metas del lab, tener menos grados de libertad y ser más fáciles de defender.

6.2 Validación del régimen

	Participación	Duración media (h)	Duración mediana (h)	Rachas
Entrenamiento: reversión	57.1%	122.1	94.0	60
tendencia	32.9%	64.1	49.5	66
crisis	10.0%	98.8	51.0	13
Prueba: reversión	60.6%	92.8	59.5	4
tendencia	39.4%	80.5	59.0	3
crisis	0.0%	n/a	n/a	0

- **Persistencia:** duración media de 64 a 122 horas, muy por encima del objetivo de 12 horas; 7.6 transiciones por mes en entrenamiento y 5.9 en prueba. Parte de esa persistencia es mecánica: una ventana de una semana cambia despacio, y por eso el régimen se detecta con retraso.
- **Separación:** silhouette de 0.45 en entrenamiento y en prueba (objetivo mayor a 0.4). Se calcula sobre las mismas variables que definen las reglas, así que sirve para comparar métodos, no como validación independiente.

- **Estabilidad fuera de muestra:** las proporciones de reversión y tendencia se parecen (57% y 33% contra 61% y 39%), pero la crisis desaparece en la prueba: ningún episodio supera el umbral de volatilidad de entrenamiento. Con 7 rachas en 33 días la evidencia es limitada.

6.3 Diferenciación del desempeño entre regímenes

Régimen de entrada	Operaciones	Win rate	Retorno bruto medio por operación	Retorno neto medio	Razón media / desv.	Contribución al capital
Entrenamiento: reversión	235	36.6%	+0.249%	-0.001%	-0.001	-26.3%
tendencia	192	38.0%	+0.230%	-0.021%	-0.010	-13.3%
crisis	3	33.3%	+0.073%	-0.176%	-0.216	-0.6%
Prueba: reversión	5	40.0%	+0.368%	+0.117%	0.052	+0.03%
tendencia	4	75.0%	+3.028%	+2.775%	0.927	+0.98%

En entrenamiento **no hay diferencia significativa** entre reversión y tendencia: la diferencia de medias del retorno bruto por operación es de 0.019 puntos porcentuales (prueba de Welch, $p = 0.93$; intervalo bootstrap del 95% de -0.37 a +0.42). En la prueba, casi todo el 1% de retorno viene de 4 operaciones de tendencia, un número demasiado pequeño para concluir nada. El retorno bruto medio por operación (0.23% a 0.25%) queda en el costo de ida y vuelta (0.25%), por lo que el retorno neto es cercano a cero en ambos regímenes.

6.4 Transiciones y su manejo

Regla: cuando el régimen vigente cambia, la posición abierta se cierra en la apertura siguiente (motivo *regime_change*); mientras está abierta conserva los parámetros del régimen en que se abrió, y un régimen sin parámetros (porque su θ no pasó el filtro de calidad) no abre posiciones.

Motivo de salida	Entrenamiento	Prueba
Señal opuesta	131	0
Cambio de régimen	101	5
Stop-loss	88	0
Cierre forzado al final del tramo o de la semana	56	2
Take-profit	45	0
Holding máximo	9	2
Total de operaciones	430	9

Casi una de cada cuatro operaciones de entrenamiento (23.5%) termina por cambio de régimen, con un retorno bruto medio de +1.0%: no se debe leer como ventaja, porque las operaciones que sobreviven hasta ver el cambio ya son una muestra seleccionada de ganadoras.




Figura 6a. Línea de tiempo de regímenes sobre el precio de cierre. Las franjas blancas son la primera semana de cada tramo, que no tiene etiqueta; las grises, huecos de datos.




Figura 6b. Distribución de las variables de régimen dentro de cada régimen (cajas con mediana; sin atípicos).




Figura 6c. Valor del portafolio del θ por régimen en entrenamiento, con los regímenes superpuestos.




Figura 6c (cont.). Valor del portafolio del θ por régimen en prueba. La línea plana del 2 al 9 de mayo es la semana sin régimen etiquetado, en la que la estrategia no puede operar.

7. Respuestas a las preguntas del lab

1. ¿Qué aporta la regla de 2 de 3? (θ único congelado, sobre entrenamiento, mismos parámetros, stop, target y costos.)

Señal	Operaciones	Retorno total	Calmar	Sharpe	Win rate
Donchian solo	179	+26.9%	1.00	1.04	40.8%
ROC solo	180	+48.7%	1.61	1.68	42.8%
Keltner solo	174	+62.6%	2.14	1.97	40.2%
2 de 3	167	+75.4%	3.40	2.32	43.7%

La regla reduce las operaciones solo entre 4% y 7%, porque la frecuencia la dominan el stop, el target y el holding, no la entrada, y sube el Calmar de 1.0 a 2.1 hasta 3.4. Salvedad: los parámetros se optimizaron para la combinación y los indicadores sueltos usan esos mismos parámetros sin reoptimizarse, por lo que la comparación favorece a la regla por construcción.

2. ¿Cuánto se degrada y qué proporción de la ventaja sobrevive? En el walk-forward, el Calmar mediano de entrenamiento de las 65 ventanas es 53.6 y el Calmar fuera de muestra del θ único es 0.25. Esa razón (0.5%) **no es una proporción justa**: el 53.6 es el máximo de 150 intentos y anualiza el retorno de un solo mes entre el drawdown de ese mes, mientras el 0.25 encadena 65 semanas. Una comparación más comparable es el retorno anualizado: con los parámetros congelados, dentro de muestra, +75.4% en 1.54 años (unos 44% anual); fuera de muestra, el θ único con filtro rinde +5.1% (4.1% anual, Sharpe 0.31, que no se distingue de cero) y el θ por régimen pierde 35.1%. Y la señal más directa de que no hay ventaja es que el retorno bruto por operación fuera de muestra (0.23% a 0.25%) es igual al costo de ida y vuelta (0.25%). En prueba, +0.7% con 8 operaciones.

3. ¿Qué tan sensible es a $\pm 20\%$ de sus parámetros? (Calmar base de 3.40.)

Parámetro	Calmar -20%	Calmar +20%	Cambio máximo	Lectura
n_donchian	3.94	3.36	+16%	estable
n_ema	3.40	3.40	0%	estable
risk_frac	3.10	3.68	-9%	estable
k	2.65	3.01	-22%	estable
n_roc	2.25	2.46	-34%	moderada
n_atr	0.54	1.86	-84%	pico
m	0.73	1.13	-79%	pico, en ambos lados
r	0.63	1.95	-82%	pico
max_hold	0.76	1.68	-78%	pico

El Calmar nunca es negativo (mínimo 0.54), pero 6 de las 18 variaciones pierden la mitad o más. **No es una meseta**: los parámetros que definen la salida y el riesgo (m , r , max_hold , n_{atr}) forman un pico, coherente con un óptimo ajustado a la muestra.




Figura 4. Calmar al variar cada parámetro óptimo en -20% y +20% (línea punteada: Calmar con el parámetro óptimo).

4. ¿A qué costo deja de ser rentable? Con el θ único congelado sobre entrenamiento, el retorno total pasa de +114.6% sin comisión a +75.4% con 12.5 puntos base por lado, y cruza cero en **47.3 puntos base por lado**: un margen de 3.8 veces la comisión del lab. Es un resultado dentro de muestra; fuera de ella, el retorno bruto medio por operación (0.23% a 0.25%) ya está en el costo. Con ese bruto, el equilibrio fuera de muestra sería de unos 11.5 a 12.4 puntos base por lado (el bruto por operación dividido entre dos), es decir, ya por debajo de los 12.5 del lab: un margen de seguridad nulo. Es una aproximación, porque ignora que el tamaño de cada operación varía.




Figura 5. Retorno total contra comisión por lado (θ único congelado, entrenamiento).

5. ¿Difiere el desempeño entre regímenes? Si no, ¿qué aporta la capa de régimen? No difiere de forma significativa (sección 6.3). Lo que aporta es, primero, el diagnóstico de que, con estos datos, la ventaja (si existe) no depende del régimen; segundo, una regla explícita de no operar sin evidencia en el régimen (la crisis casi nunca tuvo datos suficientes: solo en 13 de 65 ventanas de entrenamiento tuvo 288 barras o más); y tercero, una advertencia metodológica: repartir una ventana de un mes entre tres regímenes agrega grados de libertad con los mismos datos, y el θ por régimen salió peor que el θ único (-35.1% contra +5.1%).

6. No aplica (nivel C).

8. Ejecución, fuentes de degradación y limitaciones

Advertencia de interpretación (obligatoria). El backtest asume ejecución completa a la apertura de la barra siguiente, sin impacto de mercado ni fallas de ejecución, y solo aplica la comisión del lab. La magnitud se acota así:

- En los datos, el salto entre el cierre y la apertura siguiente tiene una desviación de 6.6 puntos base, y 1.7% de las barras son planas: las barras no son instantáneas de mercado.
- Cada 10 puntos base por lado de costo adicional (spread, deslizamiento e impacto) reduce el retorno dentro de muestra de +75.4% a +49.3%, unos 26 puntos de retorno.
- En el walk-forward por régimen, el retorno bruto medio por operación (0.23% a 0.25%) queda casi igual al costo de ida y vuelta de 0.25%. Un costo adicional de 10 puntos base por lado (0.20% por ida y vuelta) consumiría prácticamente toda la ventaja que queda.

Fuentes de degradación. *Sensibilidad de parámetros:* pico en m , r , $\max_hold$ y n_atr (sección 7, pregunta 3). *Sesgo de minería de datos:* 31,800 configuraciones, parámetros óptimos que cambian de una ventana a otra (en el walk-forward del θ único, m varía entre 11.5 y 59.9, casi todo el rango permitido) y un Calmar que cae de 53.6 a 0.25. *Cambios de régimen:* la crisis desaparece en la prueba y el régimen se detecta con una semana de retraso. *Dificultades de ejecución:* los puntos anteriores sobre costos e impacto.

Tres limitaciones para operar con capital real.

- **Ejecución idealizada:** sin impacto, spread ni profundidad de libro; la ventaja bruta por operación es del orden del costo.
- **Muestra corta y discontinua:** la prueba son 33 días con 8 a 9 operaciones, los datos tienen huecos (122 días entre diciembre y mayo) y una ventana diaria sin cotización; ninguna conclusión de la prueba es estadísticamente sólida.
- **Sobreajuste e inestabilidad:** con ventanas de un mes y diez hiperparámetros, el óptimo no se repite entre ventanas y fuera de muestra casi no sobrevive.

Otras limitaciones: no se modela el costo de préstamo de las posiciones cortas, no hay apalancamiento y la evaluación semanal cierra posiciones a la fuerza.

9. Conclusiones

- La metodología es correcta y reproducible: datos auditados y segmentados, indicadores y régimen causales (verificados con pruebas), contabilidad validada con un cálculo a mano, parámetros congelados antes de la prueba y resultados recalculables con un solo comando.
- La estrategia **no demuestra una ventaja explotable:** fuera de muestra, el retorno bruto por operación queda en el costo y el resultado no se distingue de cero. Dentro de muestra el optimizador siempre encuentra algo, y por eso la evidencia que cuenta es la de fuera de muestra.
- La capa de régimen no cambió el retorno por operación, y con ventanas de un mes empeoró el resultado. Se reporta tal cual, sin ajustar el diseño hasta que salga ganadora.
- Para avanzar harían falta más datos continuos, ventanas de entrenamiento más largas o menos parámetros, y un modelo de costos de ejecución realista.

Reproducir: `python main.py` (entre 9 y 21 minutos según la máquina; `--quick` para una verificación de 1 minuto), `pytest` para las pruebas. Semilla 42. Los números de este reporte salen de `docs/tables`, generadas por `main.py`.